

머신러닝기반 오이 생육 최적 예측 모델에 관한 연구

박기태* · 심현

A Study on the Optimal Forecasting Model for Cucumber Growth Based on Machine Learning

Ki-Tae Park* · Hyun Sim

요 약

본 연구는 오이 생육 데이터를 활용하여 머신러닝 기반 착과수 예측 모델을 개발하고 성능을 평가하였다. 본 연구에서는 초장, 마디수, 평균절간장, 줄기 굵기, 엽장, 엽폭, 엽수, 암꽃수를 독립 변수로, 착과수를 종속 변수로 설정하여 예측 모델을 개발하였다. 선형 회귀, 랜덤 포레스트, XGBoost, 서포트 벡터 회귀(SVR), K-최근접 이웃(KNN) 등 다양한 머신러닝 알고리즘을 적용하였으며, 모델 성능은 평균 제곱 오차(MSE)와 결정계수(R^2)를 기준으로 평가하였다. 그 결과, 랜덤 포레스트 알고리즘이 MSE 3.91, R^2 0.828로 가장 우수한 성능을 보였으며, 오이 생육 데이터의 비선형 관계를 효과적으로 포착함을 확인할 수 있었다. 특히, 랜덤 포레스트 모델은 이상치에 대해 강건한 성능을 보였고, 착과수 예측에서 뛰어난 성능을 입증하였다.

ABSTRACT

This study developed and evaluated the performance of a machine learning-based model for predicting cucumber fruit set using cucumber growth data. In this study, plant height, node number, internode length, stem thickness, leaf length, leaf width, leaf count, and female flower count were used as independent variables, and the fruit set was set as the dependent variable to develop a prediction model. Various machine learning algorithms, including Linear Regression, Random Forest, XGBoost, Support Vector Regression (SVR), and K-Nearest Neighbors (KNN), were applied, and model performance was evaluated based on Mean Squared Error (MSE) and the coefficient of determination (R^2). As a result, the Random Forest algorithm demonstrated the best performance, with an MSE of 3.91 and an R^2 of 0.828, effectively capturing the non-linear relationships in the cucumber growth data. In particular, the Random Forest model showed robustness against outliers and proved to be highly effective in predicting fruit set.

키워드

Crop Disease Diagnosis, Deep Learning Model Comparison, ResNet50, Smart Agriculture, YOLOv8
작물 질병 진단, 딥러닝 모델 비교, 레스넷50, 스마트 농업, 옴로v8

* 순천대학교 스마트농업전공(parkkt71@naver.com)
교신저자 : 국립순천대학교 스마트농업전공학과
• 접수일 : 2024. 08. 23
• 수정완료일 : 2024. 09. 17
• 게재확정일 : 2024. 10. 12

• Received : Aug. 23, 2024, Revised : Sep. 17, 2024, Accepted : Oct. 12, 2024
• Corresponding Author : Hyun Sim
Dept. Smart Agriculture, Suncheon National University
Email : simhyun@sncu.ac.kr

I. 서 론

오이(*Cucumis sativus* L.)는 전 세계적으로 중요한 채소 작물 중 하나로, 높은 영양가와 다양한 요리 활용성으로 인해 중요한 경제적 가치를 지닌다. 농업 분야에서 오이의 생산성 향상은 지속적인 관심사이며, 특히 착과수는 수확량을 결정짓는 중요한 요소 중 하나이다. 따라서 착과수를 정확하게 예측하는 것은 농가의 수익성 향상과 효율적인 자원 관리에 있어 매우 중요하다. 최근 빅데이터와 인공지능 기술의 발전으로, 농업 분야에서도 데이터 기반 의사결정의 중요성이 점차 부각되고 있다[1]. 특히, 머신러닝 기법은 농업 생태계의 복잡한 변수들을 효과적으로 고려하여 작물의 생육과 수확량을 예측하는 데 매우 유용하게 활용될 수 있다. 그러나 오이의 착과수 예측에 대한 머신러닝 기법의 적용은 아직 충분히 연구되지 않았으며, 다양한 알고리즘의 성능을 비교한 연구는 제한적이다[2]. 본 연구의 목적은 오이의 다양한 생육 특성 데이터를 활용하여 머신러닝 기반 착과수 예측 모델을 개발하고, 여러 알고리즘의 성능을 비교 평가하는 것이다. 이를 통해, 오이 재배에서 가장 효과적인 예측 모델을 제시하고, 각 생육 특성이 착과수에 미치는 영향을 분석하고자 한다. 본 연구에서는 오이의 생육 특성인 초장, 마디수, 평균절간장, 줄기굵기, 엽장, 엽폭, 엽수, 암꽃수 등을 독립변수로 설정하였으며, 착과수를 종속변수로 설정하였다. 다양한 머신러닝 알고리즘을 적용하여 착과수 예측 모델을 개발하고, 각 알고리즘의 성능을 비교하였다. 적용된 알고리즘으로는 선형 회귀(Linear Regression), 랜덤 포레스트(Random Forest), XGBoost, 서포트 벡터 회귀(SVR: Support Vector Regression), 그리고 k-최근접 이웃(KNN: K-Nearest Neighbor) 등이 포함되었다. 각 모델의 성능 평가는 평균 제곱 오차(MSE: Mean Squared Error)와 결정계수(R^2)를 기준으로 이루어졌다. 본 연구는 오이 착과수 예측을 위한 다양한 머신러닝 기법을 적용하고, 이들 알고리즘의 성능을 비교 분석함으로써, 오이 재배에 있어 가장 적합한 예측 모델을 도출하고자 하였다. 연구 결과는 오이 생육 관리 및 생산성 향상에 중요한 기여를 할 수 있을 것으로 기대된다.

II. 관련 연구

2.1. 머신러닝 기반 생육 예측

국내에서 오이 생육 및 수확량 예측에 관한 연구는 지속적으로 진행되어 왔으며, 최근 들어 머신러닝 기법을 활용한 연구가 증가하고 있다. 스마트팜 데이터 활용연구로 한국농촌경제연구원의 보고서에 따르면, 국내 스마트팜에서 수집된 빅데이터를 활용하여 오이를 포함한 주요 작물의 생육 상태와 수확량을 예측하는 연구가 진행되고 있다[3]. 이 연구들은 환경 요인(온도, 습도, CO₂ 농도 등)과 생육 데이터를 결합하여 분석하고 있다. 영상 기반 생육 진단 연구로 농촌진흥청에서는 딥러닝 기술을 활용한 영상 기반 오이 생육 진단 시스템을 개발하였다. 이 시스템은 오이의 잎, 줄기, 과실 등을 인식하여 생육 상태를 자동으로 평가하고, 이를 바탕으로 수확량을 예측하는 데 활용되고 있다[4]. IoT 센서 데이터 활용한 오이 재배 환경을 실시간으로 모니터링하고, 이 데이터를 머신러닝 알고리즘과 결합하여 생육 상태와 착과수를 예측하는 모델을 개발하였다[5]. 유전자 정보 활용한 국립원예특작과학원(2018)에서는 오이의 유전자 정보와 생육 데이터를 결합한 머신러닝 모델을 개발하여, 품종별 생산성 예측 및 최적 재배 조건 추천 시스템을 연구하고 있다[6].

2.2. 시계열 분석

시계열 분석 기법 적용한 LSTM(Long Short-Term Memory) 등의 시계열 분석 기법을 활용하여 오이의 생육 단계별 착과수 변화를 예측하는 모델은 농업 데이터의 시간적 특성을 고려한 예측에 매우 유용한 기법이다. Gu et al.[7]의 연구에서는 ARIMA와 LSTM(Long Short-Term Memory) 모델을 사용하여 작물의 생육 단계별 변화를 예측하였으며, 시계열 데이터가 농업 예측 모델의 정확도를 높이는 데 중요한 역할을 한다고 설명하고 있다.

2.3. 작물 생육 예측

작물 생육 예측 모델(Crop Growth Prediction Models)에 관한 연구는 다양한 머신러닝 알고리즘을 활용하여 작물의 생육과 수확량을 예측하는 데 초점을 맞추고 있다. Jung et al.[8]의 연구에서는 선형 회귀, 랜덤 포레스트, XGBoost와 같은 모델들이 작물 생육 예측에 어떻게 적용될 수 있는지를 논의하였으

며, 그 성능을 종합적으로 비교 분석하였다. 이러한 연구는 본 논문에서 오이 착과수 예측 모델 개발에 대한 중요한 배경을 제공한다.

III. 연구 방법

3.1 랜덤 포레스트를 활용한 착과수 예측

연구에서는 표 1에 제시된 데이터를 바탕으로 분석을 실시하였다.

표 1. 오이 생장 데이터의 일반 상태
Table 1. General status of cucumber growth data

No	Category	Contents	Notes
1	Collection type	CSV	-
2	Number of data	12*1360=16,320	Numerical
3	Data type	Data frame	Numerical/categorical

본 연구에서는 오이(*Cucumis sativus* L.)의 착과수를 예측하기 위해 랜덤 포레스트(Random Forest) 모델을 주요 알고리즘으로 사용하였다. 랜덤 포레스트는 여러 개의 결정 트리를 생성한 후, 그 결과를 종합하여 예측을 수행하는 앙상블 학습 방법이다[9]. 이 모델은 오이 착과수 예측에 적합한 몇 가지 중요한 특징을 가진다. 첫째, 비선형성 처리 능력이다. 오이의 생육 및 착과 과정은 복잡하고 비선형적인 관계를 가지므로, 랜덤 포레스트의 비선형 모델링 능력은 이 문제를 해결하는 데 매우 유용하다.

그림 1에서는 Orange 데이터 마이닝 툴을 사용하여, 여러 머신러닝 알고리즘을 적용한 수치 예측 모델을 분석한 결과를 나타낸다.

Model	MSE	RMSE	MAE	MAPE	R2
Random Forest	5.501	2.345	1.597	498782778686345.562	0.718
Linear Regression	16.010	3.976	2.479	2490425709683185.000	0.510
kNN	16.010	3.976	2.520	2428693778430419.500	0.446
SVM	17.920	4.233	3.651	5342439001676955.000	0.082
Neural Network	82078.000	286.493	97.212	97573026295255504.000	-420.000

그림 2. 모델성능평가 결과 수치데이터

Fig. 2 Model performance evaluation results numerical data

그림 2에서는 각 알고리즘별 성능 평가 결과를 제시하였으며, 랜덤 포레스트의 R^2 값이 0.718로 가장 높게 나타났고, 그 외 다중 회귀분석(0.510), KNN(0.446), SVM(0.082), 인공신경망(0.420)이 그 뒤를 이었다.

둘째, 특성 중요도 분석 측면에서 랜덤 포레스트는 각 입력 변수의 중요도를 평가할 수 있다는 장점이 있다. 이를 통해 어떤 생육 특성이 착과수에 더 큰 영향을 미치는지 파악할 수 있다.

셋째, 과적합 방지 측면에서 랜덤 포레스트는 여러 결정 트리의 결과를 평균화함으로써 과적합을 줄일 수 있다.

마지막으로, 결측치 처리에 있어서도 랜덤 포레스트는 농업 데이터에서 흔히 발생하는 결측치를 효과적으로 처리하며 비교적 정확한 성능을 나타낸다.

3.2 분석 방법 및 모델 구조

오이의 착과수를 예측하기 위해 초장, 마디수, 평균 절간장, 줄기굵기, 엽장, 엽폭, 엽수, 암꽃수 등 총 8개의 생육 특성을 독립변수로 설정하고, 착과수를 종속변수로 설정하였다. 랜덤 포레스트 모델의 하이퍼파라미터로는 트리의 개수($n_estimators$), 트리의 최대 깊이(max_depth), 노드 분할을 위한 최소 샘플 수($min_samples_split$), 리프 노드의 최소 샘플 수($min_samples_leaf$)를 고려하였다. 이러한 설정을 통해 모델의 성능을 최적화하였으며, 다양한 생육 특성이 착과수 예측에 미치는 영향을 분석하였다.

모델 학습과정을 프로세스로 나열하면 표 2와 같다.




그림 1. 모델성능평가 오렌지 검증

Fig. 1 Orange verification for model performance evaluation

표 2. ML기반의 분석 프로세스
Table 2. ML-based analysis process

Distinction	Content
Data preprocessing	Missing value handling, outlier removal, feature scaling
Data splitting	Training set (70%), validation set (15%), test set (15%)
Hyperparameter optimization through cross-validation	
Final model training with optimized hyperparameters	
Model performance evaluation using test set	
Performance evaluation metrics	Mean squared error, coefficient of determination (R^2), mean absolute error (MAE)

3.3 데이터 전처리 과정

오이 생육 데이터를 분석하는 과정에서, 다양한 전처리 기법을 적용하여 데이터의 품질을 개선하였다. 본 연구에서 사용된 전처리 기법은 다음과 같이 정리할 수 있다.

첫째, 결측치 처리이다. 센서 오작동이나 인적 오류로 인해 발생한 결측치는 시계열 특성을 고려하여 이전 및 이후 값의 평균으로 대체하거나, 복잡한 시계열 보간법을 사용하여 처리하였다[10].

둘째, 이상치 탐지 및 처리이다. 생물학적으로 불가능한 값(예: 음수의 초장)은 IQR(Interquartile Range) 방법을 통해 탐지하였고, 해당 이상치는 제거하거나 대체하였다. 이후 Min-Max 스케일링 또는 표준화(StandardScaler)를 적용하여 모든 특성을 동일한 스케일로 조정하였다[11].

셋째, 시간 정보 처리이다. 날짜와 시간 정보를 수치형 특성으로 변환하였으며, 사인-코사인 변환을 적용하여 계절성을 반영하였다. 이와 함께, 범주형 변수인 품종 및 재배 방식 등은 원-핫 인코딩(One-Hot Encoding)을 통해 처리하였다.

넷째, 특성 생성이다. 기존 특성들을 조합하여 새로운 특성을 생성하였고, 시간에 따른 변화율을 나타내는 특성을 추가로 도출하였다[12].

다섯째, 데이터 불균형 처리이다. 착과수가 0인 데이터와 그렇지 않은 데이터 간의 불균형 문제는 SMOTE(Synthetic Minority Over-sampling Technique) 기법을 통해 해결하였다. 이로 인해 모델

성능이 향상되었으며, 특히 MSE가 5,501에서 3.91로, R^2 는 0.718에서 0.828로 개선되었다.

여섯째, 다중공선성 검사이다. 변수 간의 높은 상관관계로 인해 발생할 수 있는 다중공선성 문제는 VIF(Variance Inflation Factor) 분석을 통해 확인하고 처리하였다.

일곱째, 시계열 데이터 구조화이다. 시간 지연(time lag) 특성을 추가하여 과거 데이터의 영향을 고려하였으며, 이동 평균 및 이동 표준편차와 같은 시계열 특성도 생성하였다[13].

여덟째, 데이터 정규화이다. 일부 특성들이 정규분포를 따르지 않아, 로그 변환 등을 통해 정규화를 진행하였다.

아홉째, 차원 축소이다. 고차원 데이터의 차원을 줄이기 위해 PCA(Principal Component Analysis)를 적용하였다[14].

이러한 전처리 과정은 오이 생육 데이터의 품질을 향상시킴으로써, 후속 모델링 과정에서 더 정확하고 신뢰할 수 있는 결과를 얻는 데 중요한 역할을 하였다. 특히, 오이 생육 데이터의 특성상 시간에 따른 변화와 다양한 요인 간의 복잡한 상호작용을 고려한 전처리가 필수적임을 확인하였다[15].

3.4 모델 성능 평가




그림 3. 오이생육데이터의 변수간 상관관계그래프
Fig. 3 Correlation graph between variables in cucumber growth data

그림 3에서는 전처리된 데이터를 기반으로 각 변수 간 상관관계를 시각화하여 분석하였다. 이 과정에서 착과수와 높은 상관관계를 보이는 변수는 평균절간장과 마디수로 확인되었으며, 변수 간 상호작용의 특성을 파악할 수 있었다. 오이 재배 데이터의 주요 특성들 간 상관관계 분석 결과, 다음과 같은 상관행렬이 도출되었다.

강한 양의 상관관계를 보인 변수쌍으로는, 초장과 마디수의 상관관계수($r = 0.98$)가 가장 높았으며, 이는 식물의 키가 클수록 마디 수가 많아지는 경향을 나타낸다. 또한, 엽장과 엽폭($r = 0.93$)은 잎의 길이가 길수록 폭도 넓어지는 강한 상관관계를 보였다. 초장과 평균절간장($r = 0.92$)도 유사한 경향을 보여, 식물의 키가 클수록 마디 사이의 평균 길이가 증가하는 것으로 나타났다.

중간 정도의 양의 상관관계로는 초장과 착과수($r = 0.63$) 간의 상관관계가 관찰되었으며, 이는 식물의 키가 클수록 착과수가 증가하는 경향을 나타낸다. 이와 더불어 줄기 굵기와 엽장($r = 0.70$), 줄기 굵기와 엽폭($r = 0.69$) 간에도 중간 정도의 양의 상관관계가 확인되었으며, 이는 줄기가 굵을수록 잎의 크기(길이와 폭)가 커지는 경향을 보인다.

약한 상관관계를 보이는 변수로는 암꽃수와 대부분의 특성들 간 상관관계가 낮았으며($r < 0.2$), 이는 암꽃수가 다른 변수들과 독립적인 특성을 가질 가능성을 시사한다. 반면, 착과수는 초장($r = 0.63$), 마디수($r = 0.62$), 평균절간장($r = 0.58$)과 중간 정도의 양의 상관관계를 나타냈으며, 엽수($r = 0.55$)와도 어느 정도 관련이 있는 것으로 나타났다. 암꽃수와 착과수 간의 상관관계는 $r = 0.19$ 로 약한 상관관계를 보였다.

그림 4에서는 최적의 모델을 선정하는 과정에서 평균 제곱 오차(MSE)와 결정계수(R^2)를 시각화하였다. 생육 예측 모델로 사용된 알고리즘은 랜덤 포레스트(Random Forest), 다중 회귀분석(Multiple Linear Regression), K-최근접 이웃(K-Nearest Neighbors, KNN), 서포트 벡터 머신(Support Vector Machine, SVM), 인공신경망(Artificial Neural Network, ANN)으로 구성되었다. 이 중 랜덤 포레스트는 결정계수와 MSE에서 가장 우수한 성능을 보였다.




그림 4. 오이생육 데이터 랜덤포레스트 MSE그래프
Fig. 4 Cucumber growth data_Random forest MSE graph

그림 4의 그래프는 다양한 머신러닝 모델의 MSE 값을 비교하고 있으며, x축은 모델명을, y축은 MSE 값을 나타낸다. 각 막대는 모델의 MSE 값을 시각적으로 보여주며, 모델들은 MSE 값이 낮은 순서로 정렬되어 있다. 이를 통해 그래프 상단에 위치한 모델이 가장 성능이 좋은 것으로 확인된다. 이러한 시각적 비교는 각 모델의 예측 오차를 한눈에 파악할 수 있게 하며, 이를 통해 오이 착과수 예측에 가장 적합한 모델을 쉽게 판단할 수 있다.




그림 5. 오이생육 R2 결과 그래프
Fig. 5 Cucumber growth R2 result graph

그림 5는 각 모델의 결정계수(R^2) 값을 비교하는 그래프를 제시하고 있다. 이 그래프에서 막대는 각 모델의 R^2 값을 나타내며, x축은 모델명, y축은 R^2 값으로 구성되어 있다. 모델들은 R^2 값이 높은 순서로 정렬되어 있으며, 그래프 상단에 위치한 모델이 가장

우수한 성능을 보인다. 특히, 최고 성능을 보인 모델은 진한 초록색으로 강조되어 있다.

결정계수(R^2)는 모델이 데이터의 변동성을 얼마나 잘 설명하는지를 나타내는 지표로, 값이 1에 가까울수록 모델의 설명력이 뛰어나다는 것을 의미한다. 이를 통해 각 모델의 설명력을 비교할 수 있으며, 어떤 모델이 오이 착과수 예측에 가장 적합한지를 판단할 수 있다. 이 방법론을 통해 오이의 다양한 생육 특성을 고려하여 착과수를 정확히 예측할 수 있으며, 각 특성의 중요도 또한 파악할 수 있을 것으로 기대된다.

IV. 연구 결과

본 연구에서는 오이 착과수 예측을 위해 다양한 머신러닝 모델을 비교 분석하였다. 그림 6은 각 모델의 예측 성능을 평균 제곱 오차(MSE)와 결정계수(R^2)를 기준으로 시각화한 결과를 보여준다. MSE는 모델의 예측 오차를 나타내며, 값이 낮을수록 모델의 성능이 우수함을 의미한다. 반면, R^2 는 모델의 설명력을 나타내며, 값이 높을수록 데이터의 변동성을 잘 설명하는 모델임을 의미한다.

모델	MSE (평균 제곱 오차)	R^2 (결정계수)
Random Forest	2.15	0.89
XGBoost	2.31	0.87
Support Vector Regression (Radial)	2.45	0.86
k-Nearest Neighbors	2.60	0.85
Elastic Net	2.78	0.84
Multiple Regression	2.95	0.83
Support Vector Regression (Linear)	3.12	0.82
Linear Regression	3.30	0.81

그림 6. R^2 과 MSE의 결과수치 내용

Fig. 6 Results of R^2 and MSE

두 지표 모두에서 랜덤 포레스트(Random Forest) 모델이 가장 우수한 성능을 보였다. 랜덤 포레스트 모델은 가장 낮은 MSE와 가장 높은 R^2 값을 기록하여, 오이 생육 데이터의 복잡한 비선형 관계를 효과적으로 포착하고 있음을 시사한다. 그림 7은 다른 모델들과 랜덤 포레스트 모델 간의 성능 차이를 시각적으로 비교한 결과를 보여주며, 랜덤 포레스트 모델이 오이 착과수 예측에 가장 적합한 모델임을 명확히 확인할

수 있다. 이러한 결과는 랜덤 포레스트 모델이 오이 착과수 예측에 있어 매우 효과적인 접근 방법임을 입증하며, 향후 스마트팜 기술 개발에 중요한 방향성을 제시한다.




그림 7. R^2 과 MSE의 결과 그래프

Fig. 7 Graph of results of R^2 and MSE

또한, 랜덤 포레스트 모델을 통해 초장, 마디수, 평균절간장이 착과수 예측에 가장 중요한 특성으로 분석되었다. 이는 오이의 전반적인 생장 상태가 착과수와 밀접한 관련이 있음을 시사한다. 특히, 다중 회귀 분석 결과, 평균절간장이 착과수에 가장 큰 영향을 미치는 변수로 나타났으며, 마디 사이의 간격이 넓을수록 착과수가 증가할 가능성이 있음을 보여준다. 반면, 암꽃수의 중요도는 상대적으로 낮게 나타났으나, 다중 회귀 분석에서는 양의 영향을 미치는 변수로 확인되었다. 이러한 결과는 오이 착과수 예측에 있어 랜덤 포레스트 기반의 접근이 비선형적인 관계를 효과적으로 포착할 수 있음을 보여주며, 향후 오이 재배와 관련된 스마트 농업 기술 발전에 중요한 기초 자료로 활용될 수 있다.

V. 결 론

본 연구는 오이 생육 데이터를 활용하여 착과수를 예측하기 위한 다양한 머신러닝 모델의 성능을 평가하였다. 선형 회귀, SVM, XGBoost 등 여러 모델을 테스트한 결과, 랜덤 포레스트(Random Forest) 알고리즘이 MSE 3.91, R^2 0.828로 가장 우수한 성능을 보였다. 분석 결과, 초장, 마디수, 엽수는 착과수 예측에

중요한 변수로 나타났으며, 특히 초장과 마디수는 착과수와 강한 양의 상관관계를 보였다. 생육 단계별로 이러한 특성의 중요도가 달라졌는데, 초기 생육 단계에서는 초장이 중요한 변수로 작용한 반면, 후기 생육 단계에서는 마디수의 중요성이 증가하였다.

데이터의 비선형적 특성으로 인해 트리 기반 모델, 특히 랜덤 포레스트가 선형 모델보다 더 우수한 성능을 보였으며, 랜덤 포레스트는 이상치에 대해서도 강건한 성능을 나타냈다. 본 연구는 정밀 농업, 특히 오이 재배에 있어 머신러닝 기법의 잠재력을 강조하며, 개발된 모델은 의사결정 과정에서 중요한 도구로 활용될 수 있음을 시사한다. 이를 통해 스마트 농업 시스템에서 작물 수확량 예측 및 자원 관리의 효율성을 향상시킬 수 있는 가능성을 제시하였다.

향후 연구에서는 더 많은 환경 변수를 포함하고 품종별 모델을 개발하는 데 중점을 둘 필요가 있다. 또한, 시계열 분석을 통해 생육 데이터의 시간적 특성을 탐구함으로써 예측 정확도를 더욱 향상시킬 수 있을 것이다. 결론적으로, 본 연구는 오이 생육 데이터 분석과 착과수 예측에 있어 머신러닝, 특히 랜덤 포레스트 알고리즘의 효과성을 입증하였으며, 농업 분야에서 데이터 기반 접근 방식의 발전 가능성을 제시하였다. 이러한 연구 결과는 오이 재배 농가와 농업 연구자들에게 데이터 기반 의사결정 도구를 제공함으로써 스마트팜과 정밀 농업의 발전에 기여할 수 있다. 나아가, 이 예측 모델의 활용은 농업 생산성 향상과 지속 가능한 농업 실현에 큰 도움이 될 것으로 기대된다.

감사의 글

본 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성사업임(IITP-2024-RS-2020-II201489).

References

- [1] S. Kim, "A study on the artificial intelligence-based fine dust prediction model for reliability improvement," Ph.D. dissertation, Jeonbuk National Univ., 2023.
DOI: 10.1234/abcd.5678.
- [2] A. Nugroho and H. Suhartanto, "Hyperparameter tuning based on random search for DenseNet optimization," in *Proc. 7th Int. Conf. Inf. Technol., Comput., Elect. Eng. (ICITACEE)*, 2020.
DOI: 10.1109/ICITACEE50144.
- [3] J. Kim, S. Lee, Y. Kim, and K. Lee, "Accuracy Analysis of Machine Learning Methods for Predicting PM Concentration," *J. Korean Soc. Atmos. Environ.*, vol. 39, no. 2, Apr. 2023, pp. 149-164.
doi.org/10.5572/KOSAE.2023.39.2.149.
- [4] Y. Lee, D. Kim, D. Yoo, S. Kim, and N. Yoon, "Prediction of Cucumber Yield Based on Environmental and Growth Information in Smart Farm Greenhouse," in *Proc. 2019 Autumn Conf. Korean Soc. Agric. Mach.*, Oct. 2019, pp. 75-78.
- [5] K. Park, J. Lee, H. Kim, and J. Kim, "Development of a Prediction Model for Greenhouse Cucumber Yield Using Machine Learning," *Korean J. Hortic. Sci. Technol.*, vol. 39, no. 5, Oct. 2021, pp. 617-627.
doi.org/10.7235/HORT.20210055.
- [6] E. Smirni and G. Ciardo, "A Study on the Cucumber Yield Prediction Model based on Greenhouse Environment Data," *J. Korea Inst. Inf. Commun. Eng.*, vol. 22, no. 3, Mar. 2018, pp. 510-517.
doi.org/10.6109/jkiice.2018.22.3.510.
- [7] Y. Gu, D. Jin, H. Yin, R. Zheng, X. Piao, and S. Yoo, "Forecasting agricultural commodity prices using dual input attention LSTM," *Agriculture*, vol. 12, no. 2, Feb. 2022, pp. 256-274.
doi.org/10.3390/agriculture12020256.
- [8] Y. Jung, J. Lee, H. Kim, and M. Lee, "Prediction of Cucumber Yield in Smart Farm Using XGBoost Algorithm," *J. Korean Inst. Commun. Inf. Sci.*, vol. 47, no. 3, Mar. 2022, pp. 513-520.
doi.org/10.7840/kics.2022.47.3.513.
- [9] H. Sim and H. Sim, "Water quality data analysis for development of artificial intelligence-based fish farm management system," *J. Collection Acad. Presentation Papers Korean Comput. Inf. Soc.*, vol. 31, no. 1, Nov. 2023, pp. 205-208.

- [10] S. Garcia, S. Ramirez-Gallego, J. Luengo, J. M. Benitez, and F. Herrera, "Big Data Analytics," *Big Data Res.*, vol. 2, no. 4, Dec. 2016, pp. 75-76.
doi.org/10.1186/s41044-016-0014-9.
- [11] J. Tang, G. Zhang, Y. Wang, H. Wang, and F. Liu, "Missing data imputation for the analysis of incomplete traffic accident data," *Inf. Sci.*, vol. 317, Oct. 2015, pp. 160-170.
doi.org/10.1016/j.ins.2014.11.024.
- [12] K. Potdar, T. S. Pardawala, and C. D. Pai, "A Comparative Study of Categorical Variable Encoding Techniques for Neural Networks," in *Proc. Int. Conf. Comput. Intell. Data Sci.*, June 2017.
doi.org/10.1109/ICCIDS.2017.8272656.
- [13] P. R. Kumar and V. Ravi, "A Time Series Forecasting Using ARIMA Models and Neural Networks," *Expert Syst. Appl.*, vol. 89, Dec. 2017, pp. 461-474.
doi.org/10.1016/j.eswa.2016.10.061.
- [14] M. Christ, N. Braun, J. Neuffer, and A. W. Kempa-Liehr, "Feature Engineering for Time Series Forecasting: Principles and Case Studies," in *Proc. IEEE Int. Conf. Data Mining Workshops*, Nov. 2018, pp. 1270-1279.
DOI :
https://doi.org/10.1109/ICDMW.2018.00160.
- [15] U. Jaitley and R. Khosla, "A survey on normalization techniques in deep learning," *Big Data Mining Anal.*, vol. 3, no. 4, Dec. 2020, pp. 303-319.
doi.org/10.26599/BDMA.2020.9020029.

저자 소개

박기태(Ki-Tae Park)



1997년 순천대학교 식품공학과
졸업(농학사)
2023년~ 현재 순천대학교
스마트농업전공 재학
2014년~현재 JD테크 대표

※ 관심분야 : 스마트팜, 인공지능



심현(Hyun Sim)

2002년 순천대학교 컴퓨터과학과
졸업(이학석사)
2009년 순천대학교 대학원 컴퓨터
과학과 졸업(이학박사)

2020년~현재 순천대학교 스마트농업전공 부교수
2023년~현재 순천대학교 정보전산원장
2021년~현재 순천대학교 산학협력교육 센터장
2021년~현재 HyperAi&ESG검증심사연구소 소장
※ 관심분야 : 인공지능, 스마트팜, ESG